



Universidade Federal de Mato Grosso

Programa de Pós-Graduação em Engenharia Elétrica (PPGEE)

Estimação de Parâmetros de Linha de Transmissão por Metaheurísticas Populacionais

Como quatro algoritmos de otimização descobrem os parâmetros elétricos de uma linha de 200 km usando apenas medições com ruído

Vinicius Marcos Domingues Conceição

Disciplina de Metaheurísticas (1S/2026) • Prof. Raoni F. S. Teixeira

Motivação: por que esse problema importa?



Tudo no planejamento e na proteção do sistema elétrico depende de conhecer bem os parâmetros da linha:

Proteção

Relés calculam onde ocorreu a falta usando R' e X' . Parâmetro errado = relé desliga o trecho errado.

Fluxo de potência

Estudos de operação e perdas usam o modelo da linha. Erro nos parâmetros distorce tudo depois.

Estimação de estado

O 'retrato' em tempo real da rede assume parâmetros corretos para combinar as medições.

O problema: o valor de catálogo envelhece

- O fabricante informa os parâmetros no comissionamento — mas temperatura, solo e envelhecimento mudam os valores reais ao longo dos anos.
- Hoje há PMUs (medidores fasoriais) nos dois extremos da linha medindo tensão e corrente — com ruído de $\sim 3\%$ (SNR = 30 dB).
- **A pergunta do trabalho: dá para recuperar os 4 parâmetros reais usando só essas medições ruidosas? Com qual precisão? E qual algoritmo faz isso melhor?**

O problema em uma frase

Encontrar $\theta = (R', X', C', G')$ que melhor explica as 5000 medições de tensão e corrente feitas nos dois extremos da linha.



Quanto menor $f(\vartheta)$, melhor o chute explica o que os PMUs mediram. Estimar parâmetros vira um problema de OTIMIZAÇÃO: achar o ϑ que minimiza f .

Linha: 200 km, 230 kV, 60 Hz

Medições: 5000 amostras (V_o , I_o , V_L , I_L)

Ruído: SNR = 30 dB (~3% por fasor)

Verdade θ^* : $R'=0,050$ $X'=0,488$ $C'=8,94\text{nF}$ $G'=0$

A ponte com a disciplina: cada conceito aplicado

Este trabalho é o roteiro da disciplina aplicado de ponta a ponta a um problema real do meu mestrado:

Conceito visto em aula	Onde aparece no trabalho
Formulação e classificação de problemas	Função objetivo $f(\theta)$; NLP não-convexo contínuo, 4 variáveis, mono-objetivo
Teorema No Free Lunch	Justifica POR QUE escolher cada algoritmo olhando a estrutura do problema
Análise de paisagem (FDC, autocorrelação)	FDC=+0,22 e ℓ_c =32,6 medidos ANTES de otimizar — preveem o resultado
Busca local e Simulated Annealing	Q-Newton (baseline) e SA com T_0 auto-calibrado p/ aceite de 80%
Algoritmos populacionais (DE, PSO)	DE/rand/1/bin ($F=0,7$, $CR=0,9$) e PSO com constrição de Clerc ($\chi=0,7298$)
Protocolo experimental rigoroso	30 sementes registradas $\times$ 3 cenários $\times$ 4 algoritmos = 360 execuções
Testes estatísticos não-paramétricos	Friedman + post-hoc de Nemenyi + Wilcoxon com correção de Holm

As regras do jogo: cenários e protocolo justo

FÁCIL $\pm 5\%$

Linha nova — catálogo confiável. Busca numa caixa estreita em torno do valor nominal.

MÉDIO $\pm 10\%$

Linha com alguns anos de operação. Incerteza moderada.

DIFÍCIL $\pm 20\%$

Linha antiga, incerteza alta. É aqui que os métodos clássicos quebram (Yang & Sen, 2023).

Para a comparação ser justa e a estatística valer:

3000

avaliações de f por execução — mesmo 'combustível' para todos os algoritmos

30

execuções com sementes 0–29 registradas — uma execução só pode ser sorte; 30 dão base estatística

360

execuções no total (3 cenários $\times$ 4 algoritmos $\times$ 30 sementes) — ~ 3 min de máquina

Os 4 competidores (em linguagem simples)

Q-Newton

- “Desce a ladeira” usando a inclinação de f
- Eficiente quando começa perto da resposta
- Reinicia de ponto aleatório quando trava
- É o método clássico — nosso BASELINE

Simulated Annealing

- Caminha aceitando pioras no começo (“quente”)
- Vai esfriando e ficando mais exigente
- Isso permite escapar de armadilhas locais
- Temperatura inicial calibrada automaticamente

Differential Evolution

- 30 soluções evoluindo JUNTAS
- Cria candidatos combinando diferenças entre elas
- Passo grande quando espalhadas, fino ao convergir
- Config. padrão da literatura ($F=0,7$, $CR=0,9$)

PSO (enxame)

- 30 partículas com posição e velocidade
- Cada uma é atraída pela sua melhor posição...
- ...e pela melhor posição já vista pelo enxame
- Fator de Clerc garante que o enxame não exploda

Q-Newton e SA seguem UMA trajetória; DE e PSO mantêm uma POPULAÇÃO que troca informação — essa é a diferença que vai decidir o jogo.

Antes de competir: o mapa do terreno (paisagem)

A disciplina ensina a medir a dificuldade do problema ANTES de otimizar. Imagine procurar o ponto mais baixo de um vale com neblina:

O vale é suave e bem-comportado

FDC = +0,22 (quem está mais perto do fundo tem altitude menor) e $\ell_c = 32,6$ (sem buracos pequenos). Em tese, ótimo para o Q-Newton.

...mas tem um penhasco escondido

25% do mapa é uma região onde $G' < 0$ (condutância negativa = linha 'amplificando' — fisicamente impossível). Lá, f fica 100× pior e a descida aponta para o lado errado.


...e uma direção quase plana

f quase não muda quando R' varia. Quem usa só a inclinação (Q-Newton) anda devagar nessa direção e 'acha' que chegou antes da hora.

Previsão (feita ANTES dos experimentos): Q-Newton vai bem na caixa estreita e degrada na larga; DE e PSO ficam estáveis.

Resultado 1: como cada algoritmo evolui

Curvas de convergência por NFE — mediana $\pm$ IC 95% (n = 30)



Como ler: eixo vertical = distância até o melhor valor possível (escala log; mais baixo = melhor). **Verde/azul (DE, PSO):** despencam até a precisão do computador usando só 25% do orçamento. **Vermelho (Q-Newton):** estaciona cedo, e a faixa larga mostra que cada execução termina num lugar diferente.

Resultado 2: o placar final (mediana de 30 execuções)

Cenário	Algoritmo	Erro em X'	Acertou o alvo?
Fácil ($\pm 5\%$)	Q-Newton	0,82%	29 de 30
	DE / PSO	0,25%	30 de 30
Médio ($\pm 10\%$)	Q-Newton	1,97%	12 de 30
	DE / PSO	0,25%	30 de 30
Difícil ($\pm 20\%$)	Q-Newton	3,40%	2 de 30
	DE / PSO	0,25%	30 de 30

“Acertar o alvo” = chegar ao melhor valor que o ruído permite (excesso $\leq 10^{-4}$).

A queda do Q-Newton (29 $\rightarrow$ 12 $\rightarrow$ 2) é exatamente o reference shift problem de Yang & Sen (2023) — e o SA fica no meio: sempre acerta, mas com menos precisão (0,4–0,8% em X').

Por que o método clássico falha? (verificado nos dados)

Ele para antes da hora

- 1 Na direção de R' o vale é quase plano. O critério de parada dispara e o L-BFGS-B “acha” que convergiu num platô. Medimos: cada execução faz 11–18 reinícios e o melhor resultado estaciona em $1,4\text{--}7,5 \times 10^{-4}$ — sempre acima do alvo de 10^{-4} .

Um quarto dos reinícios nasce no penhasco

- 2 ~25% dos pontos de partida caem na região $G' < 0$, onde a descida aponta para o lado errado. Essas tentativas morrem em poucas avaliações e desperdiçam orçamento.

A população resolve os dois problemas

- 3 No DE, o passo é a diferença entre soluções: grande quando a população está espalhada, fino ao convergir — refina R' sem parar antes da hora. No PSO, o enxame “resgata” as partículas que nasceram na região ruim.

A diferença é real ou foi sorte? Três testes respondem

Friedman — o juiz geral

- Pergunta: “os 4 algoritmos têm o mesmo desempenho?”
- Resposta: NÃO — $\chi^2 = 260,3$ com $p = 3,9 \times 10^{-56}$
- Tradução: a chance de ser acaso é desprezível
- Ranking: DE (1,10) > PSO (1,90) > SA (3,00) > Q-N (4,00)

Nemenyi — quem difere de quem

- Compara os ranks par a par (CD = 0,494)
- Todos os 6 pares diferem ($p \leq 1,9 \times 10^{-4}$)
- Até DE vs PSO difere em RANK (0,80 > 0,494)...
- ...mas veja o teste ao lado antes de concluir

Wilcoxon — o duelo direto

- Compara os VALORES de cada par, cenário a cenário
- Q-Newton e SA perdem com $p \approx 10^{-8}$ (Holm)
- DE vs PSO: $p = 1,0 \rightarrow$ empate de verdade
- Eles chegam ao MESMO ponto, na precisão da máquina

Por que Nemenyi e Wilcoxon “discordam” sobre DE vs PSO? Nemenyi olha a ORDEM: o DE termina um pinga abaixo (na 12ª casa decimal!) quase sempre, e isso gera rank consistente. Wilcoxon olha o VALOR: a diferença é zero na prática. Conclusão honesta: são operacionalmente equivalentes.

A descoberta mais importante: o limite imposto pelo ruído

DE e PSO chegaram, nas 360 execuções, sempre ao MESMO ponto $\theta^\dagger$. Compare com a verdade θ^* :

Parâmetro	Verdadeiro θ^*	Estimado $\theta^\dagger$	Erro
R' [Ω/km]	0,05000	0,04857	2,86%
X' [Ω/km]	0,48800	0,48921	0,25%
C' [nF/km]	8,940	8,934	0,07%
G' [nS/km]	0,0	-2,0	2,0 nS/km

Os 2,86% em R' NÃO são culpa dos algoritmos. O ruído de 3% nas medições desloca o fundo do vale de θ^* para $\theta^\dagger$. Qualquer método que minimize f perfeitamente chega a $\theta^\dagger$. É um limite físico de identificabilidade — e vira o BASELINE do meu mestrado: um método novo só será melhor de verdade se usar informação extra (ex.: comportamento de R' com a temperatura).

Conclusões



1

DE e PSO acertaram o melhor resultado possível em 30/30 execuções dos 3 cenários — e sempre no mesmo ponto.

2

O Q-Newton reproduziu o reference shift problem da literatura: acertos 29/30 $\rightarrow$ 12/30 $\rightarrow$ 2/30 conforme a incerteza cresce.

3

A análise de paisagem PREVIU esse resultado antes dos experimentos (região $G' < 0$ + direção plana de R').

4

DE e PSO empatam na prática (Wilcoxon $p = 1,0$): a escolha entre eles pode ser por conveniência de implementação.

5

Erro de 2,86% em R' é o limite do ruído (SNR 30 dB) — baseline quantitativo para os próximos passos do mestrado.

O que a disciplina me deu: um método completo — formular, diagnosticar a dificuldade, escolher o algoritmo com justificativa, e provar o resultado com estatística.

- YANG, N.-C.; SEN, A. Parameter estimation in unbalanced three-phase distribution lines using general regression neural networks. *Applied Soft Computing*, v. 133, art. 109936, 2023.
- WOLPERT, D. H.; MACREADY, W. G. No free lunch theorems for optimization. *IEEE Trans. Evolutionary Computation*, v. 1, n. 1, p. 67–82, 1997.
- STORN, R.; PRICE, K. Differential evolution — a simple and efficient heuristic for global optimization. *J. Global Optimization*, v. 11, n. 4, p. 341–359, 1997.
- CLERC, M.; KENNEDY, J. The particle swarm — explosion, stability, and convergence in a multidimensional complex space. *IEEE Trans. Evolutionary Computation*, v. 6, n. 1, p. 58–73, 2002.
- KIRKPATRICK, S.; GELATT, C. D.; VECCHI, M. P. Optimization by simulated annealing. *Science*, v. 220, n. 4598, p. 671–680, 1983.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.
- DERRAC, J. et al. A practical tutorial on the use of nonparametric statistical tests. *Swarm and Evolutionary Computation*, v. 1, n. 1, p. 3–18, 2011.
- PAUL, C. R. *Analysis of Multiconductor Transmission Lines*. 2. ed. Wiley-IEEE Press, 2008.



Obrigado!

Perguntas são bem-vindas

Vinicius Marcos Domingues Conceição

PPGEE/UFMT • Metaheurísticas (1S/2026)

github.com/vmdconceicao/estimacao-parametros-lt-metaheuristicas