

Estimação de Parâmetros de Linha de Transmissão de Sequência Positiva por Metaheurísticas Populacionais: Estudo Comparativo com Validação Estatística Não-Paramétrica

Vinicius Marcos Domingues Conceição

Resumo—Este artigo formula a estimação dos parâmetros elétricos de sequência positiva (R' , X' , C' , G') de uma linha de transmissão (LT) como um problema de otimização contínua não-linear restrito por caixas, e avalia quatro estratégias de busca: Quasi-Newton com reinícios aleatórios (baseline), Simulated Annealing (SA), Differential Evolution DE/rand/1/bin (DE) e Particle Swarm Optimization com fator de constrição de Clerc (PSO). O dataset sintético contém $N = 5000$ medições fasoriais com ruído gaussiano complexo de SNR = 30 dB, geradas pelo modelo de parâmetros distribuídos (matriz ABCD). Três cenários de incerteza são testados: $\pm 5\%$, $\pm 10\%$ e $\pm 20\%$ em torno do valor nominal. O protocolo experimental compreende 30 execuções independentes por (cenário, algoritmo), totalizando 360 execuções com orçamento fixo de 3000 avaliações de função. O teste de Friedman rejeita equivalência com $\chi^2 = 260,3$ e $p = 3,9 \times 10^{-56}$; o post-hoc de Nemenyi (CD=0,494) estabelece o ranking $DE \prec PSO \prec SA \prec Q\text{-Newton}$, com todos os pares estatisticamente distintos. DE e PSO atingem o piso teórico imposto pelo ruído em 30/30 execuções dos três cenários, enquanto a taxa de sucesso do Q-Newton colapsa de 29/30 (cenário fácil) para 2/30 (cenário difícil) — reprodução empírica direta do *reference shift problem* documentado por Yang & Sen [6]. A análise de paisagem (FDC=+0,22; comprimento de correlação $\ell_c = 32,6$) explica quantitativamente esse comportamento pela distribuição bimodal de f e pelo mal-condicionamento em R' e C' . Um resultado adicional de interesse prático: o MAPE residual de 2,86% em R' não é falha algorítmica, mas o limite fundamental de identificabilidade imposto pelo ruído PMU de SNR = 30 dB.

Palavras-chave—Estimação de parâmetros; linha de transmissão; metaheurísticas; Evolução Diferencial; PSO; testes estatísticos não-paramétricos; matriz ABCD; PMU.

I. INTRODUÇÃO

A determinação precisa dos parâmetros elétricos de linhas de transmissão é insumo crítico para fluxo de potência, estimação de estado, análise de curto-circuito e coordenação de proteção [1]. Embora os valores nominais sejam fornecidos pelo fabricante no comissionamento, eles divergem dos parâmetros reais ao longo da vida útil da linha devido a variações de temperatura, alterações nas condições do solo, envelhecimento e modificações geométricas [2].

A literatura de estimação de parâmetros baseada em medições pode ser agrupada em três abordagens: métodos algébricos exatos baseados em fluxo de potência [3]; métodos de otimização não-linear com inicialização especializada, como o

quasi-Newton com multi-run optimization (MRO) [4]; e métodos de aprendizado de máquina, entre os quais se destacam RBFNN [5] e GRNN [6]. Yang & Sen [6] documentam o *reference shift problem* do método MRO: quando a faixa de busca é ampliada além de $\pm 5\%$, a convergência para soluções espúrias torna-se frequente.

Este trabalho conecta um problema aberto do mestrado em andamento no PPGEE/UFMT — estimação de parâmetros de LT de sequência positiva a partir de medições PMU — com os requisitos da disciplina de Metaheurísticas (1S/2026). O problema é formulado como minimização de um erro quadrático médio normalizado sobre $N = 5000$ medições fasoriais sintéticas com ruído realista. Quatro algoritmos de otimização são comparados sob protocolo experimental rigoroso. O trabalho atende integralmente ao roteiro da disciplina: formulação e classificação do problema (Seção II), fundamentação via NFL (Seção III), análise de paisagem (Seção IV), calibração documentada de hiperparâmetros e protocolo de 30 execuções com sementes registradas (Seção V), e validação por testes de hipótese não-paramétricos (Seção VI).

Contribuições

- 1) Formulação com normalização de escala (Seção II) que torna C' identificável — sem ela, o erro de tensão ($\sim 10^5$ V) dominaria completamente o de corrente ($\sim 10^2$ A).
- 2) Análise quantitativa de paisagem (Seção IV) que prevê, antes dos experimentos, por que o Q-Newton falha no cenário difícil.
- 3) Comparação estatisticamente rigorosa de 4 algoritmos (Seção VI) com Friedman + Nemenyi + Wilcoxon.
- 4) Estabelecimento do *limite de identificabilidade* de R' para SNR = 30 dB: MAPE = 2,86% irreduzível pelo critério dos mínimos quadrados.

II. FORMULAÇÃO DO PROBLEMA

A. Modelo físico

Uma LT em regime permanente senoidal de frequência $f = 60$ Hz e comprimento $\ell = 200$ km é descrita pelo vetor de parâmetros por unidade de comprimento

$$\theta = [R', X', C', G']^T \in \mathbb{R}_+^4 \quad (1)$$

com valores nominais (verdadeiros) $\theta^* = (0,050 \text{ } \Omega/\text{km}; 0,488 \text{ } \Omega/\text{km}; 8,94 \times 10^{-9} \text{ F/km}; 0 \text{ S/km})$.

A partir de (1), definem-se a impedância série $\hat{z}' = R' + jX'$ e a admitância shunt $\hat{y}' = G' + j\omega C'$, a constante de

O autor está vinculado ao Programa de Pós-Graduação em Engenharia Elétrica (PPGEE), Universidade Federal de Mato Grosso (UFMT), Cuiabá, MT, Brasil. Trabalho desenvolvido no âmbito da disciplina de Metaheurísticas (1S/2026), ministrada pelo Prof. Raoni F. S. Teixeira.

Manuscrito submetido em junho de 2026.

propagação $\hat{\gamma} = \sqrt{\hat{z}'/\hat{y}'}$ e a impedância característica $\hat{Z}_c = \sqrt{\hat{z}'/\hat{y}'}$.

A relação entre os fasores de tensão e corrente nos terminais emissor ($z = 0$) e receptor ($z = \ell$) é dada pela **matriz ABCD** (parâmetros de cadeia) [7]:

$$\begin{bmatrix} \hat{V}_L \\ \hat{I}_L \end{bmatrix} = \underbrace{\begin{bmatrix} \Phi_{11} & \Phi_{12} \\ \Phi_{21} & \Phi_{22} \end{bmatrix}}_{\Phi(\theta)} \begin{bmatrix} \hat{V}_0 \\ \hat{I}_0 \end{bmatrix} \quad (2)$$

com $\Phi_{11} = \Phi_{22} = \cosh(\hat{\gamma}\ell)$, $\Phi_{12} = -\hat{Z}_c \sinh(\hat{\gamma}\ell)$ e $\Phi_{21} = -\hat{Z}_c^{-1} \sinh(\hat{\gamma}\ell)$.

B. Dataset sintético

O dataset `dados_SNR30.csv` contém $N = 5000$ amostras no formato $\mathcal{D} = \{(\hat{V}_0^{(k)}, \hat{I}_0^{(k)}, \hat{V}_L^{(k)}, \hat{I}_L^{(k)})\}_{k=1}^N$, geradas com os parâmetros verdadeiros θ^* e impedância de carga $\hat{Z}_L^{(k)} \sim \mathcal{U}[190, 760] \Omega$. A cada fasor é adicionado ruído gaussiano complexo branco (CWGN): $\hat{s}_{\text{meas}} = \hat{s} + \hat{n}$, com $\hat{n} \sim \mathcal{CN}(0, \sigma^2)$ e $\sigma = |\hat{s}| 10^{-\rho/20}$, $\rho = 30$ dB.

C. Função objetivo

Para cada amostra k , os fasores previstos pelo modelo são

$$\hat{V}_L^{(k)}(\theta) = \Phi_{11} \hat{V}_0^{(k)} + \Phi_{12} \hat{I}_0^{(k)}, \quad (3)$$

$$\hat{I}_L^{(k)}(\theta) = \Phi_{21} \hat{V}_0^{(k)} + \Phi_{22} \hat{I}_0^{(k)}. \quad (4)$$

O critério de qualidade é o erro quadrático médio normalizado:

$$f(\theta) = \frac{1}{N V_{\text{ref}}^2} \sum_{k=1}^N |\hat{V}_L^{(k)} - \hat{V}_L^{(k)}(\theta)|^2 + \frac{1}{N I_{\text{ref}}^2} \sum_{k=1}^N |\hat{I}_L^{(k)} - \hat{I}_L^{(k)}(\theta)|^2 \quad (5)$$

onde $V_{\text{ref}}^2 = \frac{1}{N} \sum_k |\hat{V}_L^{(k)}|^2$ e $I_{\text{ref}}^2 = \frac{1}{N} \sum_k |\hat{I}_L^{(k)}|^2$.

Justificativa da normalização. Sem os fatores V_{ref}^2 e I_{ref}^2 , o termo de tensão dominaria em $\approx 10^6$ o de corrente, tornando C' praticamente não-identificável. A normalização garante contribuições adimensionais comparáveis. Em termos simples: a função objetivo responde “quão bem este chute de parâmetros explica o que os PMUs mediram?” — quanto menor f , melhor a explicação.

D. Problema de otimização e cenários

$$\theta^\dagger = \arg \min_{\theta \in \mathbb{R}^4} f(\theta) \quad \text{s.a.} \quad \theta_i^{\min} \leq \theta_i \leq \theta_i^{\max}, \quad i = 1, \dots, 4 \quad (6)$$

As caixas de busca simulam a incerteza em relação ao valor nominal $\theta^{(0)} \equiv \theta^*$. Três cenários são avaliados (Tabela I).

Para $G' = 0$, a caixa é simétrica com amplitude $\pm 20\% \cdot |\omega C'|$. O problema é classificado como NLP não-convexo contínuo de baixa dimensão ($n = 4$).

Tabela I
CENÁRIOS DE INCERTEZA AVALIADOS

Cenário	Faixa de busca	Contexto prático
Fácil	$[0,95; 1,05] \cdot \theta^*$	Linha nova
Médio	$[0,90; 1,10] \cdot \theta^*$	Operação há anos
Difícil	$[0,80; 1,20] \cdot \theta^*$	Incerteza alta

E. Piso teórico

Com SNR = 30 dB, o resíduo em θ^* é não-nulo. Verificação numérica: $f(\theta^*) = 5,179 \times 10^{-3}$. Avaliando f com fasores reconstruídos deterministicamente (sem ruído), obtém-se $f = 0$ — confirmando que o código é fisicamente consistente e que o resíduo decorre exclusivamente do ruído das medições. Esse valor é o **piso absoluto**: nenhum algoritmo pode atingir $f < 5,179 \times 10^{-3}$ com esses dados.

F. Métrica externa

Seguindo Yang & Sen [6], reporta-se também o MAPE por parâmetro:

$$\text{MAPE}_i = \left| \frac{\theta_i^\dagger - \theta_i^*}{\theta_i^*} \right| \times 100\%, \quad i \in \{R', X', C'\}. \quad (7)$$

III. FUNDAMENTAÇÃO ALGORÍTMICA E NFL

A. Teorema No Free Lunch

O Teorema NFL [8] estabelece que, sobre todos os problemas possíveis, qualquer par de algoritmos tem desempenho médio idêntico. A superioridade de um método só pode ser demonstrada identificando as propriedades estruturais que o favorecem.

Para o problema (6), três propriedades definem o nicho algorítmico relevante: (i) suavidade local — f é analítica em todo o domínio, o que favorece busca por gradiente; (ii) não-convexidade global — existe uma região patológica associada a $G' < 0$: condutância shunt negativa equivale a “geração” de potência ao longo da linha, transformando a atenuação natural em amplificação e fazendo as previsões do modelo explodirem; isso cria mínimos locais espúrios; (iii) mal-condicionamento direcional — f varia muito mais em X' do que em R' e C' , dificultando a convergência em gradiente nessas direções.

B. Descrição dos algoritmos

Os quatro algoritmos comparados estão descritos na Tabela II.

O fator de constrição de Clerc [12] $\chi = 2/|2 - \phi - \sqrt{\phi^2 - 4\phi}|$, com $\phi = \phi_1 + \phi_2 = 4,1$, garante estabilidade analítica das trajetórias do PSO. A temperatura inicial do SA é calibrada automaticamente para taxa de aceite inicial $\approx 80\%$.

IV. ANÁLISE DE PAISAGEM

A análise de paisagem caracteriza f antes de qualquer otimização, fornecendo previsões verificáveis sobre o comportamento dos algoritmos. Todas as métricas são calculadas sobre a caixa do cenário difícil ($\pm 20\%$).

Tabela II
ALGORITMOS COMPARADOS E CONFIGURAÇÃO

Algoritmo	Tipo	Parâmetros
Q-Newton	Trajatória, gradiente	L-BFGS-B; $ftol=10^{-12}$; reinícios aleatórios
SA	Trajatória, estocástico	$\alpha=0,995$; $L=20$; $\sigma=10\%$ da caixa; T_0 auto
DE	Populacional	$N_p=30$; $F=0,7$; $CR=0,9$; $rand/1/bin$
PSO	Populacional	$N_p=30$; $\phi_1=\phi_2=2,05$; $\chi=0,7298$ (Clerc)

A. Fitness-Distance Correlation

O FDC é o coeficiente de Pearson entre $f(\theta)$ e a distância normalizada $d(\theta, \theta^*)$, calculado sobre 5000 amostras uniformes:

$$FDC = +0,219. \quad (8)$$

Pelo critério padrão [15], $|FDC| > 0,15$ com sinal positivo caracteriza paisagem benevolente: pontos mais próximos do ótimo tendem a ter custo menor.

B. Comprimento de correlação

Caminhada aleatória gaussiana de 2000 passos ($\sigma = 2\%$ da caixa por dimensão):

$$r(1) = 0,970 \quad \Rightarrow \quad \ell_c = \frac{-1}{\ln r(1)} = 32,6 \text{ passos.} \quad (9)$$

Valor $\ell_c > 20$ classifica a paisagem como suave.

Isoladamente, FDC positivo e ℓ_c alto sugeririam que o Q-Newton deveria ser competitivo. Os dois achados abaixo alteram esse diagnóstico.

C. Distribuição bimodal de f

A Fig. 1 apresenta os seis painéis da análise. O histograma (Painel 2) revela **distribuição bimodal**: um lóbulo em $\log_{10} f \approx -2,2$ (região saudável, próxima do piso) e outro em $\log_{10} f \approx -0,3$ ($\approx 100\times$ pior). Cerca de 25% das amostras uniformes caem no lóbulo ruim. A causa foi identificada numericamente: o lóbulo corresponde à metade da caixa com $G' < 0$ (correlação $r = -0,73$ entre a posição de G' e o pertencimento ao lóbulo; fixando os demais parâmetros em θ^* , $G' = -6,7 \times 10^{-7}$ S/km produz $f = 0,53$, contra $f = 8,1 \times 10^{-3}$ no extremo positivo). Em termos simples: condutância negativa faz a linha “amplificar” em vez de atenuar, e o erro do modelo explode.

D. Mal-condicionamento direcional

Os mapas de calor (R', X') e (R', C') mostram contornos quasi-horizontais: f varia apenas $\Delta \log_{10} f \approx 0,18$ ao longo de R' , contra $\Delta \log_{10} f \approx 0,33$ ao longo de X' . O gradiente em R' é portanto uma ordem de grandeza menor do que em X' , e o L-BFGS-B converge lentamente nessa direção.

E. Diagnóstico e previsão

A Tabela III consolida o diagnóstico e registra as previsões que serão verificadas na Seção VI.

Tabela III
DIAGNÓSTICO DE PAISAGEM E PREVISÕES POR CLASSE DE ALGORITMO

Indicador	Q-Newton	DE / PSO
FDC = +0,22 (benevolente)	Converge quando parte da região saudável	Vantagem marginal
$\ell_c = 32,6$ (suave)	Gradiente estável, convergência rápida	Sem obstáculo específico
$\sim 25\%$ no lóbulo ruim ($G' < 0$)	Reinícios desperdiçados; degrada com faixa maior	Cobre ambos os lóbulos; convergência robusta
R', C' mal-condicionados	MAPE residual alto com orçamento fixo	Passo escala com dispersão da pop.

V. METODOLOGIA EXPERIMENTAL

A. Protocolo

- 30 sementes (0–29) por (cenário, algoritmo) — registradas para reprodutibilidade total.
- $3 \times 4 \times 30 = 360$ execuções totais.
- Orçamento fixo: NFE = 3000 avaliações de f .
- Ambiente: Python 3.12, NumPy 1.26, SciPy 1.12, scikit-posthocs 0.13.

B. Métricas e testes estatísticos

Variável primária dos testes: excesso sobre o piso, $e = f(\theta^*) - f(\theta^*)$. Taxa de acerto: n_{hits} execuções (de 30) com $e \leq 10^{-4}$.

Teste de Friedman [13]: $k = 4$ tratamentos, $N = 90$ blocos (3 cenários $\times$ 30 sementes), não-paramétrico, pareado.

Post-hoc de Nemenyi [13]: diferença crítica $CD = q_{0,05} \sqrt{k(k+1)/(6N)}$, com diagrama CD.

Wilcoxon signed-rank [14]: pares dentro de cada cenário, correção de Holm-Bonferroni ($m = 6$).

VI. RESULTADOS E ANÁLISE ESTATÍSTICA

A. Curvas de convergência

A Fig. 2 exhibe as curvas de convergência (mediana e IC 95% sobre 30 execuções) em escala logarítmica do excesso e . DE e PSO atingem $e \lesssim 10^{-9}$ em ~ 500 –800 NFE (menos de 25% do orçamento) nos três cenários, com banda IC praticamente degenerada. SA estabiliza em 10^{-5} – 10^{-4} . Q-Newton mostra IC crescente do cenário fácil ao difícil, refletindo a mistura de execuções bem-sucedidas e fracassadas.

B. Tabela mestra de resultados

A Tabela IV sintetiza os resultados sobre as 30 execuções por célula. O IQR de DE e PSO é da ordem de 10^{-14} : todas as 30 sementes convergem para o mesmo ponto. A taxa de acerto do Q-Newton cai de 29/30 para 2/30 — reprodução empírica do *reference shift problem* de [6].

C. Distribuição de MAPE em X'

A Fig. 3 exhibe os box-plots de $\text{MAPE}_{X'}$. As caixas de DE e PSO colapsam em um único ponto (IQR nulo), enquanto a dispersão do Q-Newton cresce monotonicamente com a dificuldade do cenário.

Análise de paisagem — cenário DIFÍCIL (80-120% de θ^*)




Figura 1. Análise de paisagem — cenário difícil ($\pm 20\%$). **Painel 1:** FDC = +0,219 — correlação entre f e distância ao ótimo (5000 amostras). **Painel 2:** Histograma de $\log_{10} f$ — distribuição bimodal; linha vermelha tracejada marca o piso $f(\theta^*)$. **Painel 3:** Autocorrelação da caminhada aleatória; comprimento de correlação $\ell_c = 32,6$ passos. **Painéis 4-6:** Mapas de calor de $\log_{10} f$ nos planos (R', X') , (R', C') e (X', C') ; a estrela vermelha marca θ^* . Notar a quasi-insensibilidade de f em relação a R' (contornos horizontais no Painel 4).

Curvas de convergência por NFE — mediana $\pm$ IC 95% ($n = 30$)




Figura 2. Curvas de convergência — mediana e IC 95% sobre 30 execuções. Eixo y : excesso $f(\theta) - f(\theta^*)$ em escala logarítmica. DE e PSO convergem para precisão de máquina em menos de 25% do orçamento; Q-Newton exibe variabilidade crescente do cenário fácil ao difícil.




Figura 3. Box-plots de MAPE para X' (30 execuções por caixa, escala logarítmica). As caixas de DE e PSO são degeneradas — todas as execuções convergem ao mesmo ponto.

D. Teste de Friedman

Com $k = 4$ tratamentos e $N = 90$ blocos, variável = excesso e :

$$\chi_F^2 = 260,28, \quad p = 3,91 \times 10^{-56}. \quad (10)$$

H_0 é rejeitada com margem de 56 ordens de grandeza. Em termos simples: a chance de a diferença observada entre os algoritmos ser fruto do acaso é desprezível. Os ranks médios são: DE: 1,10; PSO: 1,90; SA: 3,00; Q-Newton: 4,00.

Tabela IV
MEDIANA DE f , IQR E MAPE POR PARÂMETRO (30 EXECUÇÕES POR CÉLULA). PISO TEÓRICO: $f(\theta^*) = 5,178 \times 10^{-3}$.

Cenário	Algoritmo	Md f	IQR f	Md MAPE $_{R'}$	Md MAPE $_{X'}$	Md MAPE $_{C'}$	Acertos/30
Fácil	Q-Newton	5,204e-3	2,71e-5	2,81%	0,82%	1,54%	29
	SA	5,181e-3	2,88e-6	2,95%	0,41%	0,22%	30
	DE	5,178e-3	1,89e-14	2,86%	0,25%	0,07%	30
	PSO	5,178e-3	1,84e-13	2,86%	0,25%	0,07%	30
Médio	Q-Newton	5,308e-3	8,88e-5	5,61%	1,97%	2,88%	12
	SA	5,187e-3	4,73e-6	3,63%	0,53%	0,39%	30
	DE	5,178e-3	5,45e-14	2,86%	0,25%	0,07%	30
	PSO	5,178e-3	4,85e-13	2,86%	0,25%	0,07%	30
Difícil	Q-Newton	5,544e-3	3,51e-4	11,06%	3,40%	4,99%	2
	SA	5,199e-3	2,28e-5	8,04%	0,81%	0,58%	30
	DE	5,178e-3	1,22e-13	2,86%	0,25%	0,07%	30
	PSO	5,178e-3	9,04e-13	2,86%	0,25%	0,07%	30

Tabela V
POST-HOC DE NEMENYI: DIFERENÇAS DE RANK MÉDIO E P-VALORES

Par	$ \Delta \text{rank} $	p (Nemenyi)	Sig. ($\alpha = 0,05$)
Q-Newton vs DE	2,90	$< 10^{-15}$	***
Q-Newton vs PSO	2,10	$< 10^{-15}$	***
Q-Newton vs SA	1,00	$1,2 \times 10^{-6}$	***
SA vs DE	1,90	$< 10^{-15}$	***
SA vs PSO	1,10	$6,5 \times 10^{-8}$	***
DE vs PSO	0,80	$1,9 \times 10^{-4}$	***

$< 10^{-15}$: valor abaixo da precisão numérica de máquina (64 bits).




Figura 4. Diagrama de diferença crítica de Nemenyi ($\alpha = 0,05$, $CD = 0,494$). Ausência de barras de equivalência: todos os pares diferem significativamente. Ranking: DE (1,10) $\prec$ PSO (1,90) $\prec$ SA (3,00) $\prec$ Q-Newton (4,00).

E. Post-hoc de Nemenyi

Diferença crítica para $\alpha = 0,05$:

$$CD = 2,569 \sqrt{\frac{4.5}{6.90}} \approx 0,494. \quad (11)$$

Todos os seis pares superam CD (Tabela V e Fig. 4).

F. Wilcoxon par-a-par

Em todos os três cenários, as cinco comparações envolvendo Q-Newton ou SA retornam $p_{\text{Holm}} \approx 1,12 \times 10^{-8}$ (vencedor: DE ou PSO). O par DE vs. PSO retorna $p_{\text{Holm}} = 1,0$ (n.s.) em todos os cenários.

Nota sobre a aparente inconsistência Nemenyi vs. Wilcoxon. O Nemenyi separa DE e PSO ($\Delta \text{rank} = 0,80 > CD$) enquanto o Wilcoxon indica empate ($p = 1,0$). A razão é mecânica: Nemenyi opera sobre *ranks*, e DE consistentemente termina com f ligeiramente abaixo de PSO na 12.^a–14.^a casa decimal, produzindo diferença de rank estatisticamente estável. O Wilcoxon opera sobre *diferenças de valor*: como

ambos convergem para o mesmo $\theta^\dagger$ com precisão de máquina, a diferença é numericamente zero. **Conclusão prática:** DE e PSO são operacionalmente equivalentes neste problema.

VII. DISCUSSÃO

A. Por que metaheurísticas vencem numa paisagem suave?

Três mecanismos explicam a falha progressiva do Q-Newton:

1) *Estagnação por mal-condicionamento (fator dominante).* Instrumentando o Q-Newton no cenário difícil, mede-se que cada execução realiza de 11 a 18 reinícios (cada corrida L-BFGS-B consome 100–500 avaliações, pois o gradiente é obtido por diferenças finitas, ≈ 5 avaliações por iteração). O melhor excesso por execução estagna em $1,4\text{--}7,5 \times 10^{-4}$ — sempre acima do limiar de acerto de 10^{-4} . A causa: nas direções quase planas (R' e G'), o critério de parada `ftol` dispara antes de o método refinar a solução; o L-BFGS-B “acredita” que convergiu quando na verdade está num platô.

2) *Reinícios desperdiçados na região patológica (fator agravante).* Cerca de 25% dos reinícios aleatórios inicializam na região $G' < 0$, onde o gradiente aponta *para longe* do ótimo global; essas corridas terminam em poucas avaliações num mínimo espúrio, desperdiçando orçamento. No cenário fácil, a caixa é tão estreita que o platô de estagnação já fica abaixo do limiar de acerto — por isso o Q-Newton acerta 29/30 ali e apenas 2/30 no difícil.

3) *Compartilhamento de informação nos populacionais.* No DE, o vetor de mutação $F(x_{r_2} - x_{r_3})$ escala com a dispersão atual da população: passo grande no início (cobre ambas as bacias), passo pequeno ao convergir. No PSO, o vetor g_{best} atrai todas as partículas para o ótimo global, incluindo as que inicializaram na região patológica.

B. O MAPE de 2,86% em R' como limite de identificabilidade

DE e PSO convergem para $\theta^\dagger = (0,04857; 0,48921; 8,9336 \times 10^{-9}; -2,0 \times 10^{-9})$ em todas as execuções. Comparação com θ^* :

- R' : 0,04857 vs. 0,05000 $\Rightarrow$ MAPE = **2,86%**
- X' : 0,48921 vs. 0,48800 $\Rightarrow$ MAPE = 0,25%
- C' : 8,934 vs. 8,940 nF/km $\Rightarrow$ MAPE = 0,07%
- G' : $-2,0$ vs. 0 nS/km $\Rightarrow$ erro abs. = 2,0 nS/km

O MAPE de 2,86% em R' **não é deficiência algorítmica**. O ruído CWGN nos quatro fasores cria um viés sistemático no ótimo da função objetivo (5), deslocando-o de θ^* para $\theta^\dagger$. Qualquer estimador que minimize (5) com SNR=30 dB chegará a $\theta^\dagger$, não a θ^* . Superar 2,86% exigiria informação adicional além das medições puras — por exemplo, regularização bayesiana sobre a temperatura do condutor ou filtragem temporal de R' .

C. Comparação com a literatura

Yang & Sen [6] reportam, para estimação trifásica em distribuição com IEEE 13-bus e ruído de $\pm 5\%$: MAPE máximo de 26,8% (Q-Newton), 4,1% (MRO), 8,9% (RBFNN) e 0,69% (GRNN). Os problemas não são diretamente comparáveis, mas a consistência qualitativa é notável: Q-Newton chega a 11% em R' neste trabalho vs. 26,8% em [6]; DE e PSO atingem 0,25% em X' , comparável ao GRNN (0,69%), sem custo de treinamento.

VIII. CONCLUSÃO

Este trabalho formulou e resolveu o problema de estimação dos parâmetros (R' , X' , C' , G') de uma LT de 200 km a partir de 5000 medições fasoriais com SNR=30 dB, comparando quatro algoritmos em 360 execuções controladas.

Os resultados principais são:

- 1) DE e PSO atingem o piso teórico em **30/30 execuções** dos três cenários, com $\text{IQR} \approx 10^{-13}$.
- 2) Q-Newton reproduz o *reference shift problem*: acertos caem de 29/30 ($\pm 5\%$) para 2/30 ($\pm 20\%$).
- 3) A análise de paisagem (distribuição bimodal + mal-condicionamento) previu quantitativamente esse resultado.
- 4) DE e PSO são operacionalmente equivalentes (Wilcoxon $p = 1,0$); a distinção pelo Nemenyi tem magnitude subnanométrica.
- 5) O MAPE de 2,86% em R' é o **limite de identificabilidade** para SNR=30 dB — baseline para métodos futuros no mestrado.

Como extensões naturais: (a) ampliar para estimação trifásica (12 parâmetros); (b) avaliar diferentes níveis de SNR; (c) investigar regularização bayesiana para superar o limite de identificabilidade de R' .

REPRODUTIBILIDADE

Todo o trabalho é reproduzido por um único script Python autocontido, `METAHEURISTICA.py`, que executa em sequência: validação da função objetivo, análise de paisagem (Fig. 1), as 360 execuções do experimento e a análise estatística completa (Figs. 2, 3 e 4). Para reproduzir os resultados, basta colocar o script na mesma pasta que o arquivo `dados_SNR30.csv` e executar:

```
python METAHEURISTICA.py
```

O script gera automaticamente todas as figuras e tabelas do artigo. Um modo de teste rápido (menos sementes) está disponível com `python METAHEURISTICA.py -rapido`.

Sementes: 0–29 (experimento) e 42 (paisagem), fixadas no código. Ambiente de referência: Python 3.12, NumPy 1.26, SciPy 1.12, scikit-posthocs 0.13, matplotlib 3.9.

O código-fonte completo e o conjunto de dados estão disponíveis no repositório:

<https://github.com/vmdconceicao/estimacao-parametros-lt-metaheurísticas>

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Em conformidade com as regras da disciplina, o autor declara que utilizou a ferramenta de inteligência artificial generativa Claude (Anthropic) como apoio nas seguintes atividades: implementação e depuração dos scripts Python do experimento, formatação do manuscrito em $\text{\LaTeX}$ e revisão textual. A formulação do problema, a escolha metodológica, a execução dos experimentos, a conferência dos resultados numéricos e as conclusões são de responsabilidade do autor, que revisou e validou todo o conteúdo gerado com auxílio da ferramenta. Todos os resultados são reproduzíveis de forma independente por meio dos scripts e sementes aleatórias documentados na seção de Reprodutibilidade.

REFERÊNCIAS

- [1] A. Abur e A. G. Expósito, *Power System State Estimation: Theory and Implementation*. CRC Press, 2004.
- [2] J. R. Acharya, Y. Wang e W. Xu, “Temporary overvoltage and GPR characteristics of distribution feeders with multigrounded neutral,” *IEEE Trans. Power Delivery*, vol. 25, n. 2, pp. 1036–1044, 2010.
- [3] R. Dutta *et al.*, “Parameter estimation of distribution lines using SCADA measurements,” *IEEE Trans. Instrumentation and Measurement*, vol. 70, pp. 1–11, 2020.
- [4] B. Das, “Estimation of parameters of a three-phase distribution feeder,” *IEEE Trans. Power Delivery*, vol. 26, n. 4, pp. 2267–2276, 2011.
- [5] N.-C. Yang, R. Huang e M.-F. Guo, “Three-phase feeder parameter estimation using radial basis function neural networks,” *IET Generation, Transmission & Distribution*, vol. 16, n. 2, pp. 351–363, 2022.
- [6] N.-C. Yang e A. Sen, “Parameter estimation in unbalanced three-phase distribution lines using general regression neural networks,” *Applied Soft Computing*, vol. 133, art. 109936, 2023.
- [7] C. R. Paul, *Analysis of Multiconductor Transmission Lines*, 2.^a ed. Wiley-IEEE Press, 2008.
- [8] D. H. Wolpert e W. G. Macready, “No free lunch theorems for optimization,” *IEEE Trans. Evolutionary Computation*, vol. 1, n. 1, pp. 67–82, 1997.
- [9] R. H. Byrd, P. Lu, J. Nocedal e C. Zhu, “A limited memory algorithm for bound constrained optimization,” *SIAM J. Scientific Computing*, vol. 16, n. 5, pp. 1190–1208, 1995.
- [10] S. Kirkpatrick, C. D. Gelatt e M. P. Vecchi, “Optimization by simulated annealing,” *Science*, vol. 220, n. 4598, pp. 671–680, 1983.
- [11] R. Storm e K. Price, “Differential evolution — a simple and efficient heuristic for global optimization,” *J. Global Optimization*, vol. 11, n. 4, pp. 341–359, 1997.
- [12] M. Clerc e J. Kennedy, “The particle swarm — explosion, stability, and convergence in a multidimensional complex space,” *IEEE Trans. Evolutionary Computation*, vol. 6, n. 1, pp. 58–73, 2002.
- [13] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” *J. Machine Learning Research*, vol. 7, pp. 1–30, 2006.
- [14] J. Derrac *et al.*, “A practical tutorial on the use of nonparametric statistical tests,” *Swarm and Evolutionary Computation*, vol. 1, n. 1, pp. 3–18, 2011.
- [15] T. Jones e S. Forrest, “Fitness distance correlation as a measure of problem difficulty for genetic algorithms,” in *Proc. 6th Int. Conf. Genetic Algorithms*, pp. 184–192, 1995.